

DRAFT

NeuralMath

Matematyczna anatomia sieci neuronowej

Polski

POLSKIE TŁUMACZENIE ORYGINAŁU W JĘZYKU
PORTUGALSKIM



Americo Cunha Jr.

neuralmath.org/pl/

$$\hat{y} = \sigma(Wx + b)$$

Nota wydawnicza

Matematyczna anatomia sieci neuronowej

Americo Cunha Jr.

Laboratório Nacional de Computação Científica (LNCC), Petrópolis, Brasil
Universidade do Estado do Rio de Janeiro (UERJ), Rio de Janeiro, Brasil

ORCID: [0000-0002-8342-0363](https://orcid.org/0000-0002-8342-0363) · americo@lncc.br



neuralmath.org/pl/

Jak cytować

Cunha Jr., A. (2026). Matematyczna anatomia sieci neuronowej [POLSKIE TŁUMACZENIE ORYGINAŁU W JĘZYKU PORTUGALSKIM]. NeuralMath, Wersja 1.0. Zenodo. <https://doi.org/10.5281/zenodo.23212380>

Artykuł oryginalny

Cunha Jr., A. A anatomia matemática de uma rede neural. Professor de Matemática Online (PMO). Manuscrito submetido, 2026.

Licencja

Tekst jest udostępniany na licencji Creative Commons Uznanie autorstwa 4.0 Międzynarodowe (CC BY 4.0). [CC-BY-4.0](https://creativecommons.org/licenses/by/4.0/)

DOI: [10.5281/zenodo.23212380](https://doi.org/10.5281/zenodo.23212380) · **Wersja:** 1.0 (2026-10)

Materiały uzupełniające

[To wydanie w sieci](#)

[Wykonywalny notebook \(Google Colab\)](#)

[Kod źródłowy \(GitHub\)](#)

Znalazłeś błąd? Poprawki i sugestie są mile widziane pod adresem <https://github.com/amicocunhajr/NeuralMath/issues>

Przedmowa

Ten tekst wyrósł z prostej idei: uczynić widocznymi operacje matematyczne zachodzące wewnątrz małej sieci neuronowej. W wielu wprowadzeniach sieci neuronowe przedstawiane są jako potężne, lecz nieprzejrzyste narzędzia. Czytelnik uczy się wywoływać bibliotekę, uruchamiać trening i obserwować krzywą straty, niekoniecznie widząc sekwencję operacji, która zamienia dane w decyzję. Tutaj wybieramy drogę odwrotną. Zaczynamy od elementarnego problemu geometrycznego, interpretujemy klasyfikator liniowy jako sztuczny neuron, wprowadzamy funkcje aktywacji, łączymy neurony w małą sieć i krok po kroku dochodzimy do gradientów, spadku gradientowego i propagacji wstecznej.

Tekst został napisany dla osób z relatywnie skromnym przygotowaniem z rachunku różniczkowego i statystyki: studentów, nauczycieli i samouków. Celem nie jest uproszczenie tematu aż do zniknięcia matematyki, lecz takie uporządkowanie wywodu, aby każda nowa idea opierała się na czymś znanym: punkcie na płaszczyźnie, prostej, złożeniu funkcji, pochodnej i regule łańcuchowej. Kod w Pythonie i NumPy pojawia się jako naturalna konsekwencja tej konstrukcji; równania i algorytm są dwoma opisami tego samego obiektu. Najlepiej więc czytać z otwartym notebukiem, uruchamiając i modyfikując każdy krok.

Ten tekst jest częścią kolekcji NeuralMath dostępnej w 26 językach. Każda wersja zachowuje te same równania, rysunki, przykłady numeryczne i numerację sekcji, dzięki czemu czytelnicy różnych języków mogą uczyć się razem. Ważną barierą w nauce matematyki i informatyki jest nie tylko trudność pojęciowa, ale również językowa, a każdy czytelnik zasługuje na punkt wejścia we własnym języku.

Moim celem jest, aby czytelnik zakończył tę drogę z mniej tajemniczym obrazem sieci neuronowej. Nie trzeba udawać, że współczesne systemy neuronowe są proste. Wystarczy pokazać, że pod skalą i złożonością dzisiejszych zastosowań wciąż działają idee matematyczne, które można badać, wyprowadzać, implementować i rozumieć.

Americo Cunha Jr. • 2026

O tym wydaniu

To jest polskie wydanie kolekcji NeuralMath, tłumaczenie portugalskiego oryginału. FILL IN: how the translations were produced. Tekst portugalski pozostaje wersją referencyjną; w razie rozbieżności ma pierwszeństwo.

Tłumaczenie nie zostało jeszcze sprawdzone przez rodzimego użytkownika języka. Poprawki są mile widziane pod adresem <https://github.com/amicocunhajr/NeuralMath/issues>.



Google Colab · PL

Czytaj z otwartym notebookiem: każdej sekcji tekstu odpowiada fragment kodu, który można uruchomić i zmodyfikować. Zeskanuj kod QR, aby otworzyć notebook tego wydania w Google Colab. Wersje w pozostałych 25 językach są wymienione na ostatniej stronie.

Matematyczna anatomia sieci neuronowej

Americo Cunha Jr 

Streszczenie

Przedstawiamy matematyczne wprowadzenie do sztucznych sieci neuronowych na przykładzie prostego problemu klasyfikacji. Klasyfikator liniowy prowadzi w naturalny sposób do pojęcia sztucznego neuronu; następnie omawiamy wagi, biasy, funkcje aktywacji oraz łączenie neuronów w niewielką sieć. Proces uczenia wprowadzamy poprzez funkcję straty, pochodne, spadek gradientu i propagację wsteczną. Na końcu model jest implementowany bezpośrednio w języku Python, dzięki czemu związek między równaniami a algorytmem staje się jawny. Celem jest pokazanie, że znane pojęcia geometrii analitycznej, algebry liniowej i rachunku różniczkowego stanowią przystępną podstawę do zrozumienia podstawowych mechanizmów sieci neuronowych.

Słowa kluczowe: sztuczne sieci neuronowe; uczenie maszynowe; edukacja matematyczna; propagacja wsteczna; Python.

1. Kiedy komputer może się uczyć?

W życiu codziennym niemal bezwiednie podejmujemy decyzje klasyfikacyjne. Patrząc na owoc, szybko rozpoznajemy, czy jest to jabłko, czy pomarańcza; gdy na telefon przychodzi wiadomość, odróżniamy prawidłową korespondencję od niechcianej reklamy; w analizie medycznej kilka pomiarów może być łączonych, aby wesprzeć decyzję; a w instytucjach finansowych przed przyznaniem kredytu ocenia się wiele informacji. We wszystkich tych przykładach kilka cech rozpatruje się jednocześnie, aby uzyskać odpowiedź.

W wielu tradycyjnych programach komputerowych reguły prowadzące do takiej odpowiedzi są jawnie zapisane przez programistę. Podejście to działa dobrze, gdy reguły są znane i można je jasno sformułować. Staje się mniej skuteczne, gdy dane są bardzo zróżnicowane albo gdy trudno z góry określić wszystkie warunki potrzebne do podjęcia dobrej decyzji. Prowadzi to do naturalnego pytania:

Czy możemy zbudować program, który nauczy się reguły decyzyjnej na podstawie przykładów, zamiast otrzymać tę regułę z góry?

Jest to jedna z centralnych idei *uczenia maszynowego*, dziedziny sztucznej inteligencji zajmującej się metodami dopasowywania modeli do danych [2, 3]. W problemie uczenia nadzorowanego algorytm otrzymuje przykłady wraz z poprawnymi odpowiedziami, a naszym celem jest znalezienie modelu, który potrafi także generować użyteczne predykcje

dla przypadków niewykorzystywanych podczas treningu. Wśród wielu modeli opracowanych w tym celu szczególne znaczenie zyskały *sztuczne sieci neuronowe*, stosowane między innymi w rozpoznawaniu obrazów, przetwarzaniu języka, analizie sygnałów i prognozowaniu szeregów czasowych [6].

Wykorzystanie sieci neuronowych jako pomostu między matematyką, obliczeniami i edukacją szkolną było już omawiane na łamach *Professor de Matemática Online* przez Batistę i Martinsa [1], którzy przedstawiają aktywność związaną z kształceniem nauczycieli, Pythonem i rozpoznawaniem cyfr. Niniejszy artykuł przyjmuje uzupełniającą perspektywę. Naszym głównym celem jest odsłonięcie matematyki wewnątrz niewielkiej sieci neuronowej, poczynawszy od geometrii analitycznej, a następnie przechodząc krok po kroku do obliczania gradientu i ręcznej implementacji propagacji wstecznej.

Mimo wyrafinowania współczesnych zastosowań matematyczny rdzeń sieci neuronowej można wprowadzić przy użyciu stosunkowo dobrze znanych pojęć. Na podstawowym poziomie sieć neuronowa jest złożeniem funkcji, których parametry są dostrajane na podstawie danych. Zaczynamy od prostego problemu geometrycznego, reinterpretujemy prostą rozdzielającą jako sztuczny neuron, łączymy kilka neuronów, analizujemy rolę funkcji aktywacji i pokazujemy, jak pochodne mogą służyć do automatycznej regulacji parametrów sieci. Następnie implementujemy kompletny, niewielki przykład w Pythonie, zachowując bezpośrednią zgodność między równaniami i kodem.

2. Matematyczna reprezentacja problemu

Aby zrozumieć działanie sieci neuronowej, zaczniemy od celowo uproszczonego problemu: odróżniania jabłek od pomarańczy. Owoc ma wiele cech, które mogłyby być przydatne w tym zadaniu, takich jak kolor, masa, średnica, tekstura czy zapach. Początkowy model matematyczny nie musi jednak obejmować całej tej złożoności. Wykorzystamy tylko dwie łatwo mierzalne wielkości: masę w gramach oraz średnicę w centymetrach.

Każdy owoc będziemy zatem reprezentować uporządkowaną parą


$$(x_1, x_2),$$

gdzie

$$x_1 = \text{masa} \quad \text{oraz} \quad x_2 = \text{średnica}.$$

Para (155, 7.2) reprezentuje więc owoc o masie 155 g i średnicy 7.2 cm. Zastępując obiekt fizyczny dwoma pomiarami liczbowymi, przyporządkowujemy każdemu owocowi punkt na płaszczyźnie kartezjańskiej: pierwsza współrzędna oznacza masę, a druga średnicę. Rysunek 1 ilustruje tę reprezentację dla hipotetycznego zbioru jabłek i pomarańczy.

Ta transformacja zmienia sposób postrzegania problemu. Zamiast pytać bezpośrednio, jak rozpoznać jabłko lub pomarańczę, możemy zadać pytanie geometryczne: jak rozdzielić na płaszczyźnie punkty należące do dwóch klas? Taka zmiana punktu widzenia ma fundamentalne znaczenie w uczeniu maszynowym. Obrazy, teksty, dźwięki i sygnały eksperymentalne muszą zostać przekształcone w reprezentacje numeryczne, zanim algorytm będzie mógł je przetwarzać. W naszym przykładzie każdy obiekt ma tylko dwie współrzędne; w rzeczywistych zastosowaniach reprezentacja może zawierać setki, tysiące, a nawet miliony składowych. Zasada pozostaje ta sama: każdy przykład jest związany ze zbiorem liczb, a model poszukuje reguły odwzorowującej tę reprezentację na pożądaną odpowiedź.




Rysunek 1: Od obserwacji fizycznej do modelowania matematycznego. Każdy owoc jest najpierw opisany dwiema mierzalnymi wielkościami — masą i średnicą — a następnie reprezentowany przez uporządkowaną parę (x_1, x_2) . Na płaszczyźnie masa-średnica każda obserwacja staje się punktem, dlatego odróżnianie jabłek od pomarańczy można reinterpretować jako geometryczny problem rozdzielania dwóch klas.

Zaczynamy od najprostszej dostępnej reguły geometrycznej i pytamy, czy jedna prosta może wystarczająco dobrze oddzielić punkty odpowiadające jabłkom od punktów odpowiadających pomarańczom.

3. Prosta jako klasyfikator

Gdy każdy owoc zostanie przedstawiony jako punkt na płaszczyźnie kartezjańskiej, klasyfikacja staje się problemem geometrycznym: czy prosta może oddzielić jabłka od pomarańczy? To pytanie zawiera podstawową ideę ważnej rodziny metod uczenia maszynowego nazywanych *klasyfikatorami liniowymi*.

Rozważmy prostą przecinającą chmurę danych, jak na Rysunku 2. Prosta dzieli płaszczyznę na dwie półpłaszczyzny. Jeżeli większość punktów odpowiadających jabłkom leży po jednej stronie, a większość punktów odpowiadających pomarańczom po drugiej, położenie nowego owocu względem prostej może służyć jako reguła klasyfikacji. Po zmierzeniu jego masy i średnicy reprezentujemy owoc jako punkt i określamy, po której stronie prostej ten punkt się znajduje.



Rysunek 2: Przykład klasyfikatora liniowego na płaszczyźnie masa–średnica. Prosta pełni rolę granicy decyzyjnej: punkty w jednej półpłaszczyźnie otrzymują jedną klasę, a punkty w przeciwnej półpłaszczyźnie drugą. Decyzja zależy zatem wyłącznie od tego, po której stronie prostej znajduje się punkt.

Na płaszczyźnie kartezjańskiej (x_1, x_2) prostą można opisać równaniem

$$w_1 x_1 + w_2 x_2 + b = 0, \quad (w_1, w_2) \neq (0, 0).$$

Wektor (w_1, w_2) jest prostopadły do prostej i dlatego wyznacza jej orientację, natomiast parametr b wpływa na jej położenie. Reprezentacja ta ma niewielką nadmiarowość: jednocześnie pomnożenie w_1 , w_2 i b przez tę samą niezerową stałą daje dokładnie tę samą prostą. Parametry opisujące granicę nie są więc jednoznaczne. Ich interpretacja liczbowa zależy również od skali zmiennych. Ponieważ masa jest mierzona w gramach, a średnica w centymetrach, nie należy bezpośrednio porównywać wartości liczbowych w_1 i w_2 bez uwzględnienia różnych jednostek.

Samo równanie prostej daje prosty sposób określania, po której stronie granicy znajduje się punkt. Zdefiniujmy wynik

$$s(x_1, x_2) = w_1 x_1 + w_2 x_2 + b.$$

Jeżeli $s(x_1, x_2) = 0$, punkt leży na prostej. Gdy $s(x_1, x_2) > 0$, znajduje się w jednej półpłaszczyźnie; gdy $s(x_1, x_2) < 0$, w drugiej. Jeśli przyjmiemy, że dodatnie wartości odpowiadają

jabłkom, a ujemne pomarańczom, reguła przyjmuje postać

$$\begin{cases} s(x_1, x_2) \geq 0 & \Rightarrow \text{jabłko,} \\ s(x_1, x_2) < 0 & \Rightarrow \text{pomarańcza.} \end{cases}$$

Na przykład rozważmy granicę zadaną przez

$$w_1 = \frac{1}{10}, \quad w_2 = 2, \quad b = -30.$$

Dla owocu o masie 160 g i średnicy 7.8 cm,

$$\begin{aligned} s &= \frac{1}{10} \times 160 + 2 \times 7.8 - 30 \\ &= 16 + 15.6 - 30 \\ &= 1.6. \end{aligned}$$

Ponieważ wynik jest dodatni, punkt znajduje się w półpłaszczyźnie skojarzonej przez nas z jabłkami. Klasyfikator przypisałby więc temu owocowi etykietę jabłka.

Nie każdy wybór w_1 , w_2 i b prowadzi do dobrej klasyfikacji. Niektóre proste słabo rozdzielają obie grupy, podczas gdy inne powodują mniej błędów. Problem uczenia polega właśnie na wykorzystaniu wcześniej oznaczonych przykładów do wyznaczenia wartości parametrów zmniejszających miarę błędu modelu. Zamiast programować położenie prostej bezpośrednio, chcemy, aby algorytm dostosował jej współczynniki na podstawie danych.

Jedna prosta może działać dobrze, gdy klasy są w przybliżeniu liniowo separowalne. Bardziej złożone zbiory danych mogą wymagać granicy nieliniowej. Zanim zajmiemy się tym ograniczeniem, zinterpretujemy skonstruowany klasyfikator jako podstawową jednostkę obliczeniową: sztuczny neuron.

4. Sztuczny neuron


W poprzedniej części wyrażenie

$$s = w_1x_1 + w_2x_2 + b$$

służyło do określenia, po której stronie prostej znajduje się owoc. To samo wyrażenie można traktować jako pierwszy etap obliczeń wykonywanych przez *sztuczny neuron*. Neuron otrzymuje wejścia liczbowe, łączy je przy użyciu wag i biasu, a następnie stosuje funkcję matematyczną, aby uzyskać wyjście.

W naszym przykładzie wejściami są masa x_1 i średnica x_2 . Każde wejście jest mnożone przez parametr nazywany *wagą*; iloczyny są sumowane ze stałym składnikiem b , nazywanym *biasem* (wyrazem wolnym). Rysunek 3 przedstawia schemat tego obliczenia.

Wagi określają, jak zmiany wejść wpływają na wynik. Jeżeli x_2 i wszystkie pozostałe wielkości są stałe, zmiana Δx_1 zmienia s o $w_1\Delta x_1$. Analogicznie zmiana Δx_2 zmienia wynik o $w_2\Delta x_2$. Znaczenie ma także znak: dodatnia waga powoduje, że wzrost wejścia zwiększa wynik, natomiast ujemna waga wywołuje efekt przeciwny. Interpretację tę należy stosować ostrożnie, gdy zmienne mają różne jednostki i skale. Z tego powodu w praktycznych



Rysunek 3: Schemat działania sztucznego neuronu. Każde wejście x_i jest mnożone przez wagę w_i ; iloczyny są sumowane z biasem b , tworząc wynik s . Funkcja aktywacji g przekształca następnie ten wynik w wyjście $\hat{y} = g(s)$, które może być użyte jako wielkość pośrednia lub jako końcowa predykcja.

implementacjach dane wejściowe są często normalizowane lub standaryzowane przed treningiem.

Bias b jest stałym składnikiem przekształcenia afinicznego. Geometrycznie umożliwia przesuwanie granicy decyzyjnej. Gdy $b = 0$, równanie

$$w_1x_1 + w_2x_2 = 0$$

wymusza przejście prostej przez początek układu współrzędnych. Obecność biasu pozwala przesunąć granicę w inne miejsce. Równoważnie, gdy $x_1 = x_2 = 0$, wynik jest po prostu równy $s = b$.

Wynik nie musi być końcowym wyjściem neuronu. Ogólnie stosuje się do niego *funkcję aktywacji* g :

$$\hat{y} = g(s) = g(w_1x_1 + w_2x_2 + b).$$

Obliczenie ma zatem dwa etapy,

$$s = w_1x_1 + w_2x_2 + b,$$

$$\hat{y} = g(s).$$

Dla wartości parametrów z poprzedniej części otrzymujemy $s = 1.6$. Jeśli wybierzemy funk-

cję skokową

$$g(s) = \begin{cases} 1, & s \geq 0, \\ 0, & s < 0, \end{cases}$$

wtedy $\hat{y} = g(1.6) = 1$. Zgodnie z przyjętą konwencją owoc zostaje sklasyfikowany jako jabłko. Przy takiej aktywacji decyzja zmienia się, gdy s przechodzi przez zero, dlatego granica klas jest dokładnie dana przez

$$w_1x_1 + w_2x_2 + b = 0.$$

Pojedynczy neuron jest więc prostym obiektem matematycznym o regulowanych parametrach. Jego prawdziwe znaczenie ujawnia się przy łączeniu wielu takich jednostek. Zanim jednak zbudujemy sieć, musimy zrozumieć, dlaczego funkcja aktywacji jest tak istotna.

5. Dlaczego potrzebujemy funkcji aktywacji?

Neuron najpierw oblicza wynik za pomocą przekształcenia afinicznego, a dopiero potem stosuje funkcję aktywacji. Ten drugi etap jest niezbędny, jeśli sieć neuronowa ma reprezentować złożone zależności. Aby zobaczyć dlaczego, wyobraźmy sobie sieć bez funkcji aktywacji. Każda jednostka miałaby wtedy postać

$$y = w_1x_1 + w_2x_2 + b.$$

Dla ilustracji jednowymiarowej załóżmy, że pierwsza jednostka wyznacza

$$h = ax + b$$

a druga oblicza

$$y = ch + d.$$

Po podstawieniu otrzymujemy

$$y = c(ax + b) + d = acx + (cb + d),$$

co nadal jest funkcją afiniczną zmiennej x . To samo zachodzi w wielu wymiarach: złożenie przekształceń afinicznych pozostaje afiniczne. Dodawanie wielu warstw bez operacji nieliniowej nie zwiększa więc zasadniczo możliwości reprezentacyjnych sieci; całe złożenie można byłoby zastąpić jednym przekształceniem afinicznym.

Funkcja aktywacji przełamuje to ograniczenie. Po obliczeniu wyniku s neuron stosuje zwykle nieliniowe odwzorowanie

$$h = g(s).$$

Gdy połączymy kilka takich jednostek, powstałego złożenia nie można już sprowadzić do jednego przekształcenia afinicznego. Dzięki temu sieć może tworzyć bardziej złożone granice decyzyjne.

Najprostszą funkcją aktywacji jest funkcja skokowa,

$$g(s) = \begin{cases} 1, & s \geq 0, \\ 0, & s < 0. \end{cases}$$

Daje ona decyzję binarną i jest bardzo użyteczna do zrozumienia klasyfikacji. Jej pochodna jest jednak równa zero dla $s \neq 0$ i nie istnieje w $s = 0$. Ponieważ uczenie gradientowe wykorzystuje pochodne do określenia, jak powinny zmieniać się parametry, funkcja skokowa nie nadaje się do takiego mechanizmu treningu.

Jedną z alternatyw jest funkcja sigmoidalna,

$$\sigma(s) = \frac{1}{1 + e^{-s}}.$$

Odwzorowuje ona każdą liczbę rzeczywistą na wartość ściśle między 0 i 1. Dla bardzo ujemnych s wyjście zbliża się do 0; dla bardzo dodatnich s zbliża się do 1; między tymi skrajnościami przejście jest płynne. Funkcja sigmoidalna jest różniczkowalna wszędzie, przy czym

$$\sigma'(s) = \sigma(s)(1 - \sigma(s)).$$

Ponieważ jej wartości leżą między 0 i 1, jest często stosowana w warstwie wyjściowej klasyfikatora binarnego. W ujęciu probabilistycznym, przy odpowiedniej funkcji straty, wyjście można interpretować jako oszacowanie prawdopodobieństwa klasy oznaczonej przez 1. W warstwach ukrytych sigmoid może jednak powodować trudność: dla wejść o dużej wartości bezwzględnej jej pochodna staje się bardzo mała, co przyczynia się do problemu *zanikającego gradientu* w głębokich sieciach.

Powszechnie stosowaną funkcją aktywacji w warstwach ukrytych jest ReLU (*Rectified Linear Unit*),

$$\text{ReLU}(s) = \max(0, s) = \begin{cases} 0, & s < 0, \\ s, & s \geq 0. \end{cases}$$

Choć składa się z dwóch odcinków liniowych, ReLU nie jest globalnie liniowa. Jej pochodna jest równa 0 dla $s < 0$ i 1 dla $s > 0$. W punkcie $s = 0$ zwykła pochodna nie istnieje, dlatego implementacje programistyczne przyjmują określoną konwencję dla gradientu. Dla dodatnich wejść pochodna nie maleje wraz ze wzrostem s , co pozwala uniknąć jednego z mechanizmów nasycenia funkcji sigmoidalnej.


Rysunek 4 porównuje wizualnie te trzy funkcje aktywacji: gwałtowny skok funkcji skokowej, płynne przejście sigmoidy oraz zmianę nachylenia ReLU.

Ich najważniejsze własności zestawiono poniżej.

Funkcja	Wyjście	Pochodna	Typowe zastosowanie
Skokowa	$\{0, 1\}$	Zero dla $s \neq 0$; nieokreślona w $s = 0$	Modele historyczne i przykłady dydaktyczne
Sigmoidalna	$(0, 1)$	Istnieje dla każdego s	Warstwa wyjściowa w klasyfikacji binarnej
ReLU	$[0, \infty)$	0 dla $s < 0$ i 1 dla $s > 0$	Warstwy ukryte

Szczegóły tych funkcji różnią się, lecz ich wspólną rolą pojęciową jest wprowadzenie nieliniowości. To właśnie nieliniowość pozwala niewielkiej sieci z następnej części reprezentować zależności, których nie potrafi uchwycić pojedyncza prosta.

Czytelnikom zainteresowanym dalszym pogłębieniem tematu Haykin [5] oferuje klasyczne ujęcie sieci neuronowych, natomiast Goodfellow, Bengio i Courville [3] omawiają funkcje



Rysunek 4: Porównanie trzech funkcji aktywacji często używanych we wprowadzających omówieniach sieci neuronowych. Funkcja skokowa podejmuje gwałtowną decyzję; sigmoida zapewnia płynne przejście między 0 i 1; natomiast ReLU zeruje wejścia ujemne i zachowuje dodatnie. Nieliniowe funkcje aktywacji zapobiegają redukcji stosu warstw do jednego przekształcenia afinicznego.

aktywacji oraz trening głębokich sieci w szerszym kontekście. Bezpłatnie dostępny tekst Nielsena [7] jest szczególnie przystępny w budowaniu intuicji dotyczącej neuronów, aktywacji i uczenia.

6. Budowa małej sieci neuronowej

Rozważmy teraz sieć z dwoma wejściami, jedną warstwą ukrytą zawierającą trzy neurony oraz jednym neuronem wyjściowym. Wejścia pozostają następujące:

$$x_1 = \text{masa}, \quad x_2 = \text{średnica},$$


i oba są podawane do każdego neuronu ukrytego, jak pokazano na Rysunku 5.

Niech wyjściami warstwy ukrytej będą h_1 , h_2 i h_3 . Każdy neuron otrzymuje te same dwa wejścia, lecz ma własne wagi i bias:

$$h_1 = g(w_{11}x_1 + w_{12}x_2 + b_1),$$

$$h_2 = g(w_{21}x_1 + w_{22}x_2 + b_2),$$

$$h_3 = g(w_{31}x_1 + w_{32}x_2 + b_3).$$



Rysunek 5: Dydaktyczna architektura 2–3–1 użyta do wprowadzenia obliczeń w sieci neuronowej. Dwa wejścia — masa i średnica — zasilają trzy neurony warstwy ukrytej. Ich aktywacje h_1, h_2, h_3 są następnie łączone przez neuron wyjściowy, który tworzy predykcję $\hat{y}$. Każde połączenie ma regulowaną wagę, a każdy neuron ma bias.

Choć wszystkie trzy neurony otrzymują tę samą masę i średnicę, mogą dawać różne odpowiedzi, ponieważ ich parametry są różne. Podczas treningu parametry te są dostrajane tak, aby pośrednie aktywacje stały się użyteczne dla klasyfikacji.

Trzy wielkości h_1, h_2 i h_3 są następnie przekazywane do neuronu wyjściowego, który oblicza

$$s_{\text{out}} = v_1 h_1 + v_2 h_2 + v_3 h_3 + c$$

i wytwarza

$$\hat{y} = g_{\text{out}}(s_{\text{out}}).$$

Dla naszego problemu binarnego używamy sigmoidalnego wyjścia:

$$\hat{y} = \sigma(v_1 h_1 + v_2 h_2 + v_3 h_3 + c), \quad 0 < \hat{y} < 1.$$

Przyjmując $y = 1$ dla jabłka i $y = 0$ dla pomarańczy, próg 0.5 prowadzi do decyzji klasowej

$$\hat{y} \geq 0.5 \Rightarrow \text{jabłko}, \quad \hat{y} < 0.5 \Rightarrow \text{pomarańcza}.$$

Wartości bliskie 1 są więc silnie związane z jabłkami, natomiast wartości bliskie 0 z pomarańczami. Jak wspomniano wcześniej, numeryczna interpretacja $\hat{y}$ jako prawdopodobieństwa wymaga dodatkowych założeń dotyczących modelu i jego treningu. Dla używanej tutaj reguły klasyfikacji wystarczy traktować $\hat{y}$ jako ciągłe wyjście sieci.

Kluczową cechą tej architektury jest reprezentacja pośrednia

$$(x_1, x_2) \longrightarrow (h_1, h_2, h_3) \longrightarrow \hat{y}.$$

Sieć otrzymuje dwie cechy i konstruuje trzy nowe wielkości przed wygenerowaniem końcowej odpowiedzi. Aktywacje te nie są wybierane ręcznie: zależą od wag i biasów, dlatego zmieniają się w trakcie treningu parametrów.

Mimo niewielkiego rozmiaru sieć ma już trzynaście regulowanych parametrów. Trzy neurony ukryte zawierają

$$3(2 + 1) = 9$$

parametrów, a neuron wyjściowy wnosi

$$3 + 1 = 4.$$

Zatem

$$9 + 4 = 13.$$

To samo zliczenie staje się przejrzyste w zapisie macierzowym. Zdefiniujmy

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, \quad W^{(1)} = \begin{bmatrix} w_{11} & w_{12} \\ w_{21} & w_{22} \\ w_{31} & w_{32} \end{bmatrix}, \quad \mathbf{b}^{(1)} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}.$$

Wtedy warstwę ukrytą można zapisać zwięźle jako

$$\mathbf{h} = g(W^{(1)}\mathbf{x} + \mathbf{b}^{(1)}),$$

gdzie g działa składowa po składowej. Dla wyjścia,

$$\hat{y} = \sigma(W^{(2)}\mathbf{h} + b^{(2)}),$$

przy czym

$$W^{(2)} = \begin{bmatrix} v_1 & v_2 & v_3 \end{bmatrix}.$$

Zapis ten zapowiada strukturę, która pojawi się w programie w Pythonie. Gdy owoc zostanie podany na wejście i obliczamy kolejne aktywacje aż do otrzymania $\hat{y}$, wykonujemy *propagację w przód* (ang. *forward pass*). Pozostaje kluczowe pytanie: jak automatycznie wyznaczyć trzynaście parametrów, aby predykcje były zgodne z danymi?

7. Jak uczy się sieć neuronowa?

Wagi i biasy nie są znane z góry. Muszą zostać dostrojone z wykorzystaniem przykładów, dla których znamy poprawną odpowiedź. Proces ten nazywa się *treningiem* i można go podsumować cyklem

$$\boxed{\text{predykcja}} \longrightarrow \boxed{\text{pomiar błędu}} \longrightarrow \boxed{\text{aktualizacja parametrów}} \longrightarrow \boxed{\text{powtórzenie}}.$$

Rozważmy owoc o masie 140 g i średnicy 7.0 cm, którego poprawną klasą jest pomarańcza, a więc $y = 0$. Załóżmy, że w pewnym momencie treningu sieć daje wyjście $\hat{y} = 0.80$. Prosta miarą różnicy między predykcją a wartością docelową jest błąd kwadratowy

$$E = \frac{1}{2} (y - \hat{y})^2.$$

W tym przykładzie,

$$E = \frac{1}{2}(0 - 0.80)^2 = 0.32.$$


Wyrażenie to jest *funkcją straty* dla jednego przykładu. Ponieważ jest kwadratem, $E \geq 0$, a predykcje bardziej oddalone od wartości docelowej otrzymują większą karę. Czynniki $1/2$ nie zmienia położenia minimum, lecz upraszcza pochodne. W klasyfikacji binarnej często stosuje się inne funkcje straty, zwłaszcza entropię krzyżową. Tutaj używamy błędu kwadratowego, ponieważ jego algebra jest przejrzysta i wystarcza do wprowadzenia optymalizacji oraz propagacji wstecznej [2, 3].

Jeżeli zbiór treningowy zawiera N przykładów, jedną z globalnych miar jest średnia strata

$$J = \frac{1}{N} \sum_{i=1}^N E_i.$$

Każda predykcja zależy od wag i biasów sieci, dlatego J również zależy od wszystkich tych parametrów. Trening oznacza poszukiwanie takich wartości parametrów, dla których J jest małe.

Aby zrozumieć mechanizm dostrajania, wyobraźmy sobie najpierw, że wszystkie parametry poza jedną wagą w są ustalone. Możemy wtedy traktować stratę jako funkcję $J = J(w)$. Rysunek 6 podsumowuje podstawowe etapy treningu, które teraz omówimy.



Rysunek 6: Podstawowy cykl treningu sieci neuronowej. Propagacja w przód przekształca wejścia w predykcję; funkcja straty mierzy różnicę między predykcją a wartością docelową; propagacja wsteczna oblicza gradienty z użyciem reguły łańcuchowej; a spadek gradientu wykorzystuje te gradienty do aktualizacji wag i biasów. Powtarzanie tego cyklu przez wiele epok nazywamy uczeniem.

Dla czytelników z niewielkim przygotowaniem z rachunku różniczkowego pochodną można tutaj interpretować jako miarę *lokalnej wrażliwości*: mówi ona, jak niewielka zmiana jednego parametru wpływa na stratę. Jej znak wskazuje kierunek, w którym funkcja lokalnie rośnie lub maleje, a wartość bezwzględna mierzy siłę tej lokalnej zmiany.

Pochodna

$$\frac{\partial J}{\partial w}$$

określa lokalne nachylenie. Jeśli jest dodatnia, niewielki wzrost w powoduje zwykle wzrost J , dlatego wagę należy przesunąć w przeciwnym kierunku. Jeśli jest ujemna, zwiększenie w lokalnie zmniejsza J . Oba przypadki opisuje równanie

$$w_{\text{new}} = w_{\text{old}} - \eta \frac{\partial J}{\partial w},$$

które wyraża podstawową ideę *spadku gradientu*. Dodatnia liczba η jest *współczynnikiem uczenia*; steruje długością kroku. Bardzo mała wartość może spowolnić trening, natomiast zbyt duża może prowadzić do oscylacji lub niestabilności.

Dla sieci z wieloma parametrami niech θ oznacza dowolną wagę lub bias. Aktualizacja przyjmuje postać

$$\theta_{\text{new}} = \theta_{\text{old}} - \eta \frac{\partial J}{\partial \theta}.$$

Zbiór wszystkich pochodnych cząstkowych tworzy *gradient* funkcji straty. Geometrycznie gradient wskazuje kierunek najszybszego lokalnego wzrostu, dlatego jego przeciwieństwo wyznacza lokalny kierunek spadku.

Pozostaje obliczyć te pochodne, gdy sieć jest złożeniem wielu funkcji. Podczas propagacji w przód informacja przepływa jako

w wejścia $\rightarrow$ warstwa ukryta $\rightarrow$ wyjście.

Aby określić, jak parametr we wcześniejszej warstwie wpływa na stratę, matematycznie śledzimy łańcuch zależności w kierunku odwrotnym. Procedura ta nazywa się *propagacją wsteczną* (ang. *backpropagation*). Jest to w istocie systematyczne i wydajne zastosowanie reguły łańcuchowej. Rumelhart, Hinton i Williams [8] stanowią klasyczne źródło dotyczące upowszechnienia tej procedury w sieciach z warstwami ukrytymi; Nielsen [7] podaje szczegółowe i szczególnie dydaktyczne wyprowadzenie.

Dla prostego łańcucha zależności, w którym E zależy od $\hat{y}$, ta wielkość zależy od aktywacji h , a h z kolei zależy od wagi w , reguła łańcuchowa daje

$$\frac{\partial E}{\partial w} = \frac{\partial E}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial h} \frac{\partial h}{\partial w}.$$

Każdy czynnik opisuje jeden etap wpływu w na końcową stratę. Większe sieci zawierają wiele takich łańcuchów, a propagacja wsteczna organizuje obliczenia tak, aby pochodne pośrednie mogły być ponownie wykorzystywane zamiast obliczane oddzielnie dla każdego parametru.

W praktyce trening wykorzystuje wiele przykładów. Jedno pełne przejście przez zbiór treningowy nazywa się *epoką*. Parametry mogą być aktualizowane po każdym przykładzie,

jak w dydaktycznym programie użytym dalej w artykule, albo po małych grupach przykładów zwanych *mini-batchami*, co jest typowe w większych sieciach. W obu przypadkach cykl predykcji, strat, gradientów i aktualizacji jest powtarzany przez wiele epok.

Konkretnym sposobem wizualizacji tej ewolucji jest śledzenie predykcji dla jednego ustalonego przykładu na różnych etapach treningu. Rozważmy ponownie owoc o masie 140 g i średnicy 7.0 cm, którego poprawną klasą jest pomarańcza. Tabela 1 pokazuje hipotetyczny przebieg. Wartości te nie pochodzą z konkretnego uruchomienia programu; służą jedynie do ilustracji mechanizmu.

Tabela 1: Hipotetyczna ewolucja predykcji sieci dla tego samego owocu podczas treningu. Powtarzane aktualizacje parametrów mogą przesunąć początkowo błędne wyjście w kierunku klasyfikacji zgodnej z etykietą docelową.

Epoka	Predykcja $\hat{y}$	Strata E	Klasyfikacja
1	0.86	0.37	Jabłko
5	0.71	0.25	Jabłko
10	0.55	0.15	Jabłko
20	0.31	0.05	Pomarańcza
40	0.09	0.004	Pomarańcza

Na początku wyjście jest bliskie 1 i owoc zostaje błędnie sklasyfikowany jako jabłko. W miarę dostrajania parametrów predykcja maleje i w końcu przekracza próg 0.5, prowadząc do poprawnej klasy. W tym procesie zmieniają się wartości liczbowe wag i biasów; architektura sieci pozostaje niezmienna.

Zmniejszenie straty na danych treningowych nie jest celem ostatecznym. Użyteczna sieć powinna również dobrze przewidywać dla przykładów, które nie były używane do dopasowania parametrów. Zdolność ta nazywa się *generalizacją*. Gdy model zbyt mocno dostosowuje się do specyfiki zbioru treningowego i gorzej działa na nowych danych, mamy do czynienia z *przeuczeniem* (ang. *overfitting*). W bardziej starannych ocenach dane dzieli się zwykle na zbiory treningowy, walidacyjny i testowy: pierwszy służy do dopasowania parametrów, drugi wspiera wybory dokonywane podczas rozwijania modelu, a trzeci jest zachowany do końcowej oceny. Szersze omówienie generalizacji i oceny modeli można znaleźć u Faceliego i in. [2] oraz Goodfellowa, Bengio i Courville'a [3].

Dotarliśmy zatem do matematycznego znaczenia uczenia w sieci neuronowej. W tym kontekście uczenie oznacza dostrajanie parametrów funkcji złożonej tak, aby zmniejszać miarę błędu na danych i, w idealnym przypadku, generalizować na nowe przykłady. Sieć generuje predykcję, oblicza stratę, wykorzystuje pochodne do określenia wpływu parametrów na tę stratę i wykonuje sekwencję niewielkich korekt.

8. Od matematyki do Pythona

Przechodzimy teraz od równań do wykonywalnego programu. Celem nie jest użycie wyspecjalizowanej biblioteki sieci neuronowych, lecz bezpośrednia implementacja za pomocą NumPy operacji matematycznych rozwijanych w całym artykule [4]. Pozwala to zobaczyć, linia po linii, jak w kodzie pojawiają się kombinacje liniowe, funkcje aktywacji, obliczanie straty, propagacja wsteczna i spadek gradientu.

W bardziej przekonującym przykładzie końcowym używamy syntetycznego zbioru danych rozłożonego na szerszym obszarze płaszczyzny masa-średnica. Nadal pracujemy tylko z dwiema cechami fizycznymi — masą w gramach i średnicą w centymetrach — ale tym razem rozmieszczamy 64 przykłady treningowe na rozległym obszarze płaszczyzny i rezerwujemy osiem dodatkowych przykładów do ilustracyjnego testu. Dane pozostają syntetyczne i mieszczą się w wiarygodnych zakresach dla jabłek i pomarańczy. Zostały skonstruowane tak, aby prowadzić do nieliniowej granicy decyzyjnej bez skupiania wszystkich punktów w kilku nadmiernie sztucznych klastrach.

Idea geometryczna jest prosta. Definiujemy krzywą odniesienia na płaszczyźnie masa-średnica, umieszczamy jabłka w dwóch pasmach powyżej tej krzywej, a pomarańcze w dwóch pasmach poniżej niej. Do masy i średnicy dodajemy niewielkie deterministyczne zaburzenia, dzięki czemu obserwacje zajmują szerszy obszar. Otrzymany przykład jest bogatszy od wcześniejszych ilustracji: zawiera więcej punktów, dane są rozłożone na całej dziedzinie, a odpowiednia granica decyzyjna jest wyraźnie bardziej zakrzywiona niż prosta.

W tym końcowym eksperymencie obliczeniowym powiększamy warstwę ukrytą do dwunastu neuronów ReLU. Nie zmienia to struktury pojęciowej analizowanej w poprzednich częściach; zwiększa jedynie zdolność sieci do reprezentowania bardziej złożonej granicy. Zamiast 13 parametrów dydaktycznej sieci z trzema neuronami mamy teraz 49 regulowanych parametrów: 24 wagi i 12 biasów w pierwszej warstwie, a następnie 12 wag i jeden bias w warstwie wyjściowej. Równania zachowują tę samą postać; większe stają się jedynie wektory i macierze.

Pełny program przedstawiono poniżej.

```
import numpy as np
import matplotlib.pyplot as plt
from matplotlib.lines import Line2D

def relu(s):
    return np.maximum(0, s)

def relu_derivative(s):
    return (s > 0).astype(float)

def sigmoid(s):
    return 1 / (1 + np.exp(-s))

def base_boundary(m):
    return 6.68 + 0.74*np.exp(-((m-155)/20)**2) \
        + 1.50/(1 + np.exp(-(m-202)/5))

def build_data():
    masses_1 = np.linspace(118, 212, 16)
    masses_2 = masses_1 + np.array([
        1.2, -1.1, 0.8, -1.3, 1.0, -0.8, 1.1, -1.0,
        1.3, -0.9, 0.9, -1.2, 1.0, -1.0, 0.8, -0.7
    ])
    k = np.arange(16)
```

```

a1 = np.column_stack([
    masses_1,
    base_boundary(masses_1) + 0.22 + 0.05*np.sin(0.8*k)
])
a2 = np.column_stack([
    masses_2,
    base_boundary(masses_2) + 0.58 + 0.06*np.cos(0.45*k)
])

o1 = np.column_stack([
    masses_1,
    base_boundary(masses_1) - (0.22 + 0.04*np.cos(0.7*k))
])
o2 = np.column_stack([
    masses_2,
    base_boundary(masses_2) - (0.55 + 0.05*np.sin(0.5*k))
])

X_train = np.vstack([a1, a2, o1, o2])
y_train = np.array([1.0]*32 + [0.0]*32)

X_test = np.array([
    [121.0, 7.20], [135.0, 7.45],
    [152.0, 7.75], [171.0, 7.32],
    [121.0, 6.28], [152.0, 6.86],
    [189.0, 6.48], [208.0, 7.55]
])
y_test = np.array([1,1,1,1,0,0,0,0], dtype=float)

return X_train, y_train, X_test, y_test

def predict(X, mean, std, W1, b1, W2, b2):
    Xn = (X - mean) / std
    outputs = []
    for x in Xn:
        h = relu(W1 @ x + b1)
        y_hat = sigmoid(W2 @ h + b2)
        outputs.append(y_hat)
    return np.array(outputs)

X_train, y_train, X_test, y_test = build_data()

mean = X_train.mean(axis=0)
std = X_train.std(axis=0)
Xn = (X_train - mean) / std

rng = np.random.default_rng(42)
W1 = 0.1 * rng.standard_normal((12, 2))
b1 = np.zeros(12)
W2 = 0.1 * rng.standard_normal(12)
b2 = 0.0
eta = 0.05
n_epochs = 6000
history = []

for epoch in range(n_epochs):
    for i in rng.permutation(len(Xn)):

```

```

x = Xn[i]
target = y_train[i]

z1 = W1 @ x + b1
h = relu(z1)
z2 = W2 @ h + b2
y_hat = sigmoid(z2)

delta2 = (y_hat - target) * y_hat * (1 - y_hat)
dW2 = delta2 * h
db2 = delta2
delta1 = (delta2 * W2) * relu_derivative(z1)
dW1 = np.outer(delta1, x)
db1 = delta1

W1 -= eta * dW1
b1 -= eta * db1
W2 -= eta * dW2
b2 -= eta * db2

errors = []
for x, target in zip(Xn, y_train):
    h = relu(W1 @ x + b1)
    y_hat = sigmoid(W2 @ h + b2)
    errors.append(0.5 * (target - y_hat)**2)
history.append(np.mean(errors))

def make_figure():
    masses = np.linspace(116, 214, 500)
    diameters = np.linspace(6.0, 8.85, 500)
    M, D = np.meshgrid(masses, diameters)
    grid = np.column_stack([M.ravel(), D.ravel()])
    P = predict(grid, mean, std, W1, b1, W2, b2).reshape(M.shape)

    fig, ax = plt.subplots(figsize=(9.2, 6.3))
    ax.contourf(
        M, D, P,
        levels=[0.0, 0.25, 0.50, 0.75, 1.0],
        colors=["#f3e0cb", "#ecd5c4", "#dbe7cf", "#cde3bf"],
        alpha=0.95
    )
    ax.contour(M, D, P, levels=[0.5],
               colors=["#5a1a8a"], linewidths=2.2)

    mask = y_train == 1.0
    ax.scatter(X_train[mask,0], X_train[mask,1], marker="o",
               s=48, facecolors="white", edgecolors="black",
               linewidths=1.1, label="Łabko - trening")
    mask = y_train == 0.0
    ax.scatter(X_train[mask,0], X_train[mask,1], marker="s",
               s=48, facecolors="white", edgecolors="black",
               linewidths=1.1, label="ńPomaracza - trening")
    mask = y_test == 1.0
    ax.scatter(X_test[mask,0], X_test[mask,1], marker="^",
               s=92, color="#1f77b4", label="Łabko - test")
    mask = y_test == 0.0
    ax.scatter(X_test[mask,0], X_test[mask,1], marker="x",
               s=110, color="#ff7f0e", linewidths=2.0,
               label="ńPomaracza - test")

```

```

ax.set_xlabel("Masa (g)")
ax.set_ylabel("Średnica (cm)")
ax.set_title("ŚWycie sieci neuronowej po treningu")

handles = [
    Line2D([0],[0], marker='o', markersize=9,
            markerfacecolor='white', markeredgcolor='black',
            linestyle='None', label='łJabko - trening'),
    Line2D([0],[0], marker='s', markersize=9,
            markerfacecolor='white', markeredgcolor='black',
            linestyle='None', label='ńPomaracza - trening'),
    Line2D([0],[0], marker='^', markersize=9, color='#1f77b4',
            linestyle='None', label='łJabko - test'),
    Line2D([0],[0], marker='x', markersize=10, color='#ff7f0e',
            linestyle='None', label='ńPomaracza - test'),
    Line2D([0],[0], color='#5a1a8a', lw=2.2,
            label='Granica decyzyjna sieci neuronowej')
]
ax.legend(handles=handles, loc='center left',
          bbox_to_anchor=(1.02, 0.5), frameon=True)

fig.tight_layout()
plt.show()

```

Choć kod jest dłuższy niż pierwsze równania analizowane w artykule, jego struktura pozostaje przejrzysta. Funkcja `build_data()` automatycznie generuje 64 przykłady treningowe oraz osiem ilustracyjnych przykładów testowych. Następnie standaryzujemy obie zmienne zgodnie ze wzorem

$$x_j^* = \frac{x_j - \mu_j}{\sigma_j},$$

gdzie μ_j i σ_j są obliczane wyłącznie na podstawie zbioru treningowego. Zapobiega to wpływowi zbioru testowego na dopasowanie parametrów, a jednocześnie sprowadza masę i średnicę do porównywalnych skal liczbowych.

Propagacja w przód nie zmienia się co do istoty. Jedyną różnicą jest to, że pierwsza warstwa wytwarza teraz wektor dwunastu aktywacji ukrytych. W zapisie macierzowym,

$$\mathbf{z}^{(1)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(1)}, \quad \mathbf{h} = \text{ReLU}(\mathbf{z}^{(1)}),$$

$$\mathbf{z}^{(2)} = \mathbf{W}^{(2)}\mathbf{h} + \mathbf{b}^{(2)}, \quad \hat{y} = \sigma(\mathbf{z}^{(2)}).$$

Te cztery wiersze nadal zawierają matematyczny rdzeń algorytmu. Trening również zachowuje wcześniej wprowadzoną logikę: obliczyć predykcję, zmierzyć jej błąd, propagować informację o wrażliwości wstecz za pomocą pochodnych i aktualizować parametry małymi krokami spadku gradientu.

W kodzie propagacja wsteczna w warstwie wyjściowej pojawia się w instrukcji

```
delta2 = (y_hat - target) * y_hat * (1 - y_hat)
```


a propagacja do warstwy ukrytej w instrukcji

```
delta1 = (delta2 * W2) * relu_derivative(z1)
```

po czym następuje aktualizacja wszystkich wag i biasów. Ponieważ przykłady są mieszane w każdej epoce, a parametry aktualizowane po każdej obserwacji, implementacja ta jest elementarną postacią *stochastycznego spadku gradientu*.

Dla użytego tutaj ziarna generatora losowego i hiperparametrów końcowa średnia strata jest rzędu od 10^{-5} do 10^{-4} , a wszystkie 64 przykłady treningowe wraz z ośmioma ilustracyjnymi przykładami testowymi otrzymują oczekiwaną klasyfikację. Nie należy interpretować tego jako rygorystycznej statystycznej oceny jakości: dane są syntetyczne i zostały skonstruowane w celach dydaktycznych. Ich rolą jest pokazanie, w mniej trywialnym otoczeniu, jak niewielka sieć neuronowa może nauczyć się wyraźnie nieliniowej granicy decyzyjnej.

Rysunek 7 przedstawia końcowy wynik programu na płaszczyźnie masa-średnica. Pokazano wszystkie punkty treningowe. Wyróżniona krzywa jest poziomicą $\hat{y} = 0.5$ i reprezentuje granicę decyzyjną nauczoną przez sieć; zacieniowane obszary oznaczają dwie przewidywane klasy. Okręgi oznaczają jabłka treningowe, kwadraty pomarańcze treningowe, trójkąty jabłka testowe, a krzyżyki pomarańcze testowe. Legenda została umieszczona poza głównym obszarem wykresu, aby nie zasłaniać żadnego punktu danych.



Rysunek 7: Wynik programu w Pythonie po treningu sieci neuronowej. Syntetyczny zbiór danych zawiera 64 przykłady treningowe rozmieszczone na szerokim obszarze płaszczyzny masa–średnica oraz osiem dodatkowych przykładów przeznaczonych do ilustracyjnego testu. Wyróżniona krzywa jest poziomnicą $\hat{y} = 0.5$ i reprezentuje nauczoną granicę decyzyjną; zacieniowane obszary wskazują klasy przewidywane przez sieć. Okręgi oznaczają jabłka treningowe, kwadraty pomarańcze treningowe, trójkąty jabłka testowe, a krzyżyki pomarańcze testowe.

Zaczęliśmy od prostej rozdzielającej dwie proste grupy punktów, a zakończyliśmy na bogatszym przykładzie obliczeniowym, w którym zakrzywiona granica powstaje w wyniku automatycznego dostrajania parametrów sieci. Do matematyki nie dodano niczego tajemniczego: implementacja jedynie organizuje i powtarza, na większą skalę i z dużą szybkością, kombinacje afiniczne, funkcje aktywacji, pochodne, iloczyny macierzowe i aktualizacje metodą spadku gradientu [3, 7].

Wszystkie materiały obliczeniowe związane z tym artykułem — w tym kod oraz wykonywalny notatnik Google Colab — są dostępne pod adresem <https://neuralmath.org>, który stanowi jeden punkt dostępu dla czytelników chcących analizować, odtwarzać lub modyfikować przykłady.

Oświadczenie dotyczące wykorzystania AI. Autor korzystał z ChatGPT, opracowanego przez OpenAI, jako narzędzia wspomagającego redagowanie, korektę językową, organizację wyводу oraz tworzenie ilustracji dydaktycznych. Autor ponosi pełną odpowiedzialność za ostateczną treść pracy, w tym za koncepcję i opracowanie materiału matematycznego, kod oraz wykorzystane źródła.

Literatura

- [1] M. Batista and A. O. Martins. “Redes Neurais no Ensino Básico”. *Professor de Matemática Online*, v. 10, n. 4, p. 454–481, 2022. doi: 10.21711/2319023x2022/pmo1032
- [2] K. Faceli, A. C. Lorena, J. Gama, T. A. de Almeida, and A. C. P. L. F. de Carvalho. *Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina*. 2nd ed. Rio de Janeiro: LTC, 2021.
- [3] I. Goodfellow, Y. Bengio, and A. Courville. *Deep Learning*. Cambridge, MA: MIT Press, 2016. Available at: <http://www.deeplearningbook.org>
- [4] C. R. Harris, K. J. Millman, S. J. van der Walt et al. “Array programming with NumPy”. *Nature*, v. 585, p. 357–362, 2020. doi: 10.1038/s41586-020-2649-2
- [5] S. Haykin. *Redes Neurais: Princípios e Prática*. Translation by Paulo Martins Engel. 2nd ed. Porto Alegre: Bookman, 2000.
- [6] Y. LeCun, Y. Bengio, and G. Hinton. “Deep learning”. *Nature*, v. 521, p. 436–444, 2015. doi: 10.1038/nature14539
- [7] M. A. Nielsen. *Neural Networks and Deep Learning*. Determination Press, 2015. Available at: <https://neuralnetworksanddeeplearning.com>
- [8] D. E. Rumelhart, G. E. Hinton, and R. J. Williams. “Learning representations by back-propagating errors”. *Nature*, v. 323, p. 533–536, 1986. doi: 10.1038/323533a0

Americo Cunha Jr

NeuralMath

Matematyka · sieci neuronowe · Python

Czytaj w innych językach

bn · বাংলা	العربية · ar	ja · 日本語
cs · Čeština		ko · 한국어
de · Deutsch		nl · Nederlands
el · Ελληνικά		pl · Polski
en · English		pt · Português (original)
es · Español		ro · Română
		ru · Русский
	فارسی · fa	sv · Svenska
fr · Français		tr · Türkçe
hi · हिन्दी		uk · Українська
hu · Magyar		
id · Bahasa Indonesia		vi · Tiếng Việt
it · Italiano		zh · 简体中文
		اردو · ur



<https://neuralmath.org>

DOI: 10.5281/zenodo.23212380 · CC-BY-4.0 · Wersja 1.0